



SOGANG UNIVERSITY · 강화학습의 기초

최종 프로젝트 발표

2026.06

SRAS

Sparse Reward-Aware Selector for Edge-Native RAG Pipelines

강화학습(PPO) 기반 한국어 법률 QA 문서 선택기 — 설계, 실험, 그리고 원 논문과의 비교

[A71020 김아미]

GitHub 저장소: [<https://github.com/kam5263/sras>]

발표 순서

01

프로젝트 주제 및 목표

RAG 검색의 한계와 논문 SRAS의 제안

02

환경 및 데이터셋

AI Hub 한국어 법률 QA · 전처리 파이프라인

03

State · Action · Reward 설계

정책 입력·출력과 3-항 보상 함수

04

RL 알고리즘 및 Hyperparameter

PPO + 5종 안정화 기법

05

실험 셋업

환경, 평가지표, 비교 모델

06

실험 결과

학습 곡선 · 성능 비교 · 일반화 · 신뢰구간

07

원 논문(SRAS, Muttur 2026)과의 비교

충실한 재현, 확장, 그리고 상반된 결론

08

개선 방안 및 결론

개선 방향 · 종합 결론

요약

RAG 파이프라인의 “문서 검색”을 강화학습으로 설계하기

91.5%

테스트 Hit Rate@3
(SRAS Warmup, 최고 성능)

0.38 MB

모델 크기
(98,368 파라미터)

0.03~0.04 ms

CPU/MPS 추론 지연

-8 %

PPO 적용 후 성능 변화
(Warmup 대비 하락)

본 프로젝트의 한계



- Supervised Warmup만으로 Cosine 유사도 baseline(97.0%)에 근접 — 가벼운 학습만으로 경쟁력 있는 검색기를 만들 수 있음을 확인
- 그러나 원 논문은 “PPO가 지도학습보다 우수하다”고 결론지은 반면, 본 프로젝트의 한국어 법률 QA 환경에서는 **PPO가 오히려 Warmup 대비 검색 성능을 8%를 저하시켰다** — 동일한 알고리즘으로 다른 결론이 나옴
- 이 차이를 원 논문(Muttur, 2026)과 비교·분석한다.



BACKGROUND & OBJECTIVES

프로젝트 주제 및 목표

01

연구 배경: 왜 검색 단계를 학습시키는가?

기존 RAG 검색의 한계

- RAG(Retrieval-Augmented Generation) 파이프라인의 문서 검색은 전통적으로 코사인 유사도 기반 top-k 검색으로 수행
- 이 방식은 인코더가 사전학습한 표현 공간에 전적으로 의존 — 실제 질의응답 성능을 직접 최적화하지 않음
- “의미적으로 가까움”과 “답변 생성에 실제로 도움이 됨”은 다를 수 있음 → 검색과 생성 사이의 괴리

SRAS의 제안 — 검색을 “정책”으로 재정의

- SRAS(Sparse Reward-Aware Selector)는 검색 단계에 강화학습을 도입
- 생성된 답변의 품질을 보상 신호로 활용하여, “어떤 문서를 고르면 더 좋은 답변이 나오는가”를 직접 학습하는 문서 선택 정책을 훈련
- 본 프로젝트는 ICEdge 2025 발표 논문 SRAS(Muttur, 2026)의 아이디어와 구조를 출발점으로, 한국어 법률 QA 도메인에 적용·확장한 재현·확장 연구

프로젝트 목표 및 파이프라인 구조

목표 (GOALS)



학습 기반 문서 선택

코사인 유사도 baseline 대비
성능 향상



엣지 배포 가능성

모델 크기 < 1 MB
CPU 추론 지연 < 1 ms



희박 보상 처리

PPO + 하이브리드 보상으로
안정적 학습

파이프라인 구조 (PIPELINE)





ENVIRONMENT & DATASET

환경 및 데이터셋

02

데이터셋 개요 — AI Hub 한국어 법률 QA

법령 · 판결문 · 결정례 · 해석례 4개 카테고리로 구성된 한국어 법률 QA 데이터셋을 사용.
훈련·테스트 gold document를 완전히 분리하여 데이터 누출을 방지

카테고리 구성

카테고리	ID 접두사	설명
법령	HJ_B_	법률 조문 및 규정
판결문	HJ_P_	법원 판결 문서
결정례	HJ_K_	행정 결정 사례
해석례	HJ_H_	법령 해석 사례

AI Hub 데이터셋을 선택한 이유


- 원 논문(SRAS)은 범용 영어 코퍼스(905개의 문서) 기반 — 본 프로젝트는 한국어·법률이라는 전문 도메인으로 변경하여 검증
- 법률 문서는 문장이 길고 용어가 유사해 “의미적으로 가까운 오답”이 많은 현실적인 RAG 시나리오를 제공할 것으로 가정

데이터 규모

구분	문서 수	QA pair 수	비고
훈련 (Train)	642	800	gold doc 중복 허용
테스트 (Test)	70	200	훈련 미사용 문서만

데이터 누출 방지: 훈련셋(642개의 문서)과 테스트셋(70개의 문서) 가 완전히 분리되어 있어, 모델이 “외운” 문서로 평가받을 위험이 없음.

전처리 파이프라인



5 단계 전처리 파이프라인

QA 생성 세부 사항

- 모델: qwen2.5:14b (Ollama 기반)
- 입력: 청크 전체 텍스트 (500~800자)
→ 출력: JSON 배열 [{question, answer}]
- 청크당 최대 3개 QA pair 생성

임베딩 캐시

- 인코더: jhgan/ko-sroberta-multitask (768차원, frozen)
- 임베딩은 1회 계산 후 캐시 — 학습 루프 내 재계산 없음 (속도 최적화)
- MPS(Apple Silicon) 가속 활용

Candidate Pool 구성

각 학습 스텝에서 정답(gold) 1개와 무작위 오답(distractor) 7개로 구성된 후보 풀(n=8)을 만들고, 그중 SRAS가 K=3개를 선택하도록 학습한다.

Candidate Pool (n = 8)



재현성 보장

랜덤 distractor는 매 rollout마다 seed = qa_idx로 고정 → 동일 QA에는 항상 동일한 후보 풀이 구성되어 실험 재현 가능

SRAS Selector → top-K = 3개 문서 선택
(학습: softmax 샘플링 / 추론: argmax)

왜 1 : 7 비율인가?

Hit@K 랜덤 기대값 = $K/n = 3/8 = 37.5\%$ — 베이
스라인을 명확히 정의할 수 있는 대조군 설계
(이후 실측 Random과 비교)



STATE, ACTION & REWARD DESIGN

State · Action · Reward 설계

03

State & Action 정의 & SRAS 스코어링 함수

State & Action

$$s = (q_emb , \{ d_1, d_2, \dots, d_n \})$$

- 쿼리 임베딩 $q_emb \in \mathbb{R}^{768}$ — 사용자 질문의 의미 표현
- 문서 임베딩 풀 $d_i \in \mathbb{R}^{n \times 768}$ — $n = 8$ 개 후보 문서
- 인코더는 frozen 상태로 유지 — 학습 중 갱신하지 않음

$$a = \{ i_1, i_2, i_3 \} \subset \{1, \dots, n\} , \quad |a| = K = 3$$

- 학습 시: softmax 정책에서 비복원 순차 샘플링 (탐험 ↑)
- 추론 시: argmax deterministic top-K 선택 (랜덤성 없음)

available = [0..n-1] → softmax(scores) → multinomial 샘플링 → 선택 후 available에서 제거 → K번 반복

SRAS 스코어링 함수 (모델 구조)

$$s_i = w^T \cdot \tanh (W_q q + W_d d_i)$$

additive interaction scorer — 쿼리·문서 임베딩을 각각 선형변환 후 비선형 결합하여 적합도 점수 산출 (embedding_dim = 768, hidden_dim = 64)

파라미터	크기	파라미터 수
W_q (Linear, bias 없음)	768 × 64	49,152
W_d (Linear, bias 없음)	768 × 64	49,152
w (Linear, bias 없음)	64 × 1	64
합계	—	98,368

→ 모델 크기 0.38 MB — 엣지 배포 목표(<1MB)를 충족

Reward 설계 — 3-항 하이브리드 보상 함수

$$R = \alpha \cdot F_1 + (1-\alpha) \cdot B + \beta \cdot \mathbb{1}[\text{gold} \in \text{selected}]$$

Relaxed F1

$$\alpha = 0.6$$

토큰 수준 F1, 소문자·불용어 정규화 — 답변 품질의 어휘적 일치도

BERTScore

$$1 - \alpha = 0.4$$

klue/roberta-base, lang="ko" — 답변 품질의 의미적 유사도

Doc Hit Bonus

$$\beta = 0.2$$

gold 문서 선택 시 직접 보상

답변 생성기 (Reward 계산용)

- qwen3.5:2b (Ollama HTTP API) · think:false (thinking mode 비활성화)
- 청크 텍스트 전체 사용, 동일 (쿼리, 문서) 조합은 in-memory 캐시로 재사용

보상 정규화 (Reward Normalization)

$$\hat{A}_i = (R_i - \mu_R) / (\sigma_R + \epsilon)$$

배치별 zero-mean / unit-variance
정규화 후 advantage 계산



RL ALGORITHM & HYPERPARAMETERS

강화학습 알고리즘 및 Hyperparameter

04

PPO (Proximal Policy Optimization)

순수 PyTorch 커스텀 구현 — 외부 RL 프레임워크(Stable-Baselines 등) 없이 처음부터 직접 구현하여 알고리즘 내부 동작을 완전히 통제

Clipped Surrogate Objective

$$L^{\text{CLIP}} = E_t [\min (r_t \cdot \hat{A}_t , \text{clip}(r_t, 1-\epsilon, 1+\epsilon) \cdot \hat{A}_t)]$$

확률비 (probability ratio)

$$r_t = \pi_{\theta}(a_t | s_t) / \pi_{\theta_{\text{old}}}(a_t | s_t)$$

핵심 메커니즘



Clipping으로 안정성 확보

$\epsilon = 0.2$ 범위로 정책 변화 폭을 제한 — 한 번의 업데이트가 정책을 과도하게 바꾸지 못하도록 방지



Old policy 고정 (detach)

rollout 시점의 로그 확률을 detach()하여 old policy로 고정한 뒤, update 시점에 현재 정책으로 재계산하여 비율 r_t 산출

훈련 안정화 기법

Supervised Warmup	PPO 이전 cross-entropy 사전훈련	정책 붕괴(collapse) 방지
Hybrid Reward	F1 + BERTScore 조합	희박 보상 문제 완화
Doc Hit Bonus	직접 검색 신호 추가	생성기 노이즈 우회
Reward Normalization	배치별 zero-mean / unit-var 정규화	학습 안정성 확보
Curriculum Learning	쉬운 → 어려운 순으로 점진적 노출	초기 학습 안정성 확보

Curriculum Learning 구현

epoch 진행률에 따라 활성 QA pair 수를 선형적으로 증가시켜, 초반에는 쉬운(적은) 데이터로 시작해 점차 전체 데이터로 확장

```
frac = min(1.0, 0.5 + 0.5*epoch / (max_epochs-1))
n_active = max(batch_size, int(frac * n_qa))
# 점진적으로 400 → 800
```

→ 학습 초반 정책이 쉬운 사례로 빠르게 안정화된 뒤, 점차 어려운 분포로 확장되며 강건성을 확보

Hyperparameter 설정값

파라미터	값	비고
Optimizer	AdamW	
Learning rate	1e-5	
PPO Epochs	25	
Batch size	8	
Candidates n	8	1 gold + 7 random
Top-K	3	

파라미터	값	비고
Clip ϵ	0.2	PPO clipping
Discount γ	0.99	
Reward α	0.6	F1 가중치
Doc Hit Bonus β	0.2	직접 검색 신호
Embedding dim	768	Frozen 인코더
Hidden dim	64	SRAS 내부

설계 포인트

- 원 논문과 PPO 핵심 hyperparameter(epochs=25, batch=8, lr=1e-5, γ =0.99, clip ϵ =0.2, AdamW)를 동일하게 설정 — 알고리즘 차이가 아닌 “도메인 차이”의 효과를 분리 관찰하기 위함
- Doc Hit Bonus(β =0.2)는 논문에는 없는 설정 → 논문의 reward는 전적으로 generator 품질에 의존. 그러나 컴퓨팅 자원의 한계로 이 구현은 Qwen3.5:2b를 generator로 사용. 이를 보완하기 위해 직접적인 retrieval 신호를 주어 학습 안정화를 추구.



EXPERIMENTAL SETUP

실험 셋업

05

실험 환경, 평가 지표, 그리고 4종 비교 모델

실험 환경 훈련: 642문서 / 800 QA · 테스트: 70문서 / 200 QA · 후보 풀 n=8 (1 gold + 7 random) · 단일 시드 (seed = 42)

평가 지표

Hit Rate@K

선택한 top-K 문서 안에 정답(gold) 문서가 포함된 비율 — 검색 성공 여부의 직접 지표

MRR

Mean Reciprocal Rank — gold 문서가 상위에 노출될수록 높은 점수. 순위 품질까지 반영

보조 지표 — Relaxed F1, BERTScore F1 (선택된 문서로 생성한 답변의 품질을 보조적으로 측정)

비교 모델 (4종)



Random

무작위 k개 선택

성능 하한선



Cosine Top-K

쿼리·문서 코사인 유사도

비학습 베이스라인



SRAS Warmup

지도학습 사전훈련

PPO 시작점



SRAS PPO (best)

강화학습 미세조정

최종 제안 모델




EXPERIMENTAL RESULTS

실험 결과


06

학습 곡선 — Epoch 19에서 최고 보상, 이후 완만 하락

평균 보상 (avg_reward) · Figure 1



Hit Rate (%) · Figure 2



관찰 평균 보상은 epoch 19에서 최고치(avg_reward 0.6403 · Hit 94.4%)를 기록한 뒤 소폭 하락 — Hit Rate는 Ep 15(95.4%)에서 먼저 정점을 기록. 1차 학습 대비 전반적으로 안정적이나, 후반부 *"policy drift"* 징후가 보임

Hit / Miss 보상 분리 분석 — 보상 신호는 변별력을 갖는가?

$R(\text{hit})$ = 정답 문서를 선택했을 때 평균 보상 · $R(\text{miss})$ = 놓쳤을 때 평균 보상 · $\text{Gap} = R(\text{hit}) - R(\text{miss})$ (보상 신호의 변별력)

Epoch	avg_reward	Hit Rate	R(hit)	R(miss)	Gap
1	0.6269	94.5%	0.651	0.214	0.437
5	0.6229	91.8%	0.654	0.263	0.390
9	0.6262	93.6%	0.652	0.259	0.393
15	0.6337	95.4%	0.651	0.219	0.432
20	0.6375	93.3%	0.667	0.239	0.428
25	0.6278	91.2%	0.666	0.230	0.436

관찰: 보상 신호의 변별력(Gap)과 실제 성능(Hit Rate)의 정점이 일치하지 않음

- $R(\text{hit}) > R(\text{miss})$ 이 모든 epoch에서 성립 — 보상 함수가 “문서를 맞혔는가”를 어느 정도 변별하고 있음을 확인
- 그러나 Gap이 가장 큰 epoch 1(0.437)가 아니라, epoch 15(Gap 0.432)에서 Hit Rate가 최고치(95.4%)를 기록 — 보상 신호의 “크기”만으로는 학습 성과를 설명하기 부족하며, 생성기가 틀린 문서로도 그럴듯한 답변을 만들어 신호를 흐릴 가능성을 시사

최종 성능 비교 — 테스트셋 (4개 모델)

n = 200

모델	Hit@3	MRR
SRAS Warmup	91.5%	0.7859
SRAS PPO	83.5%	0.7375
Cosine Top-K	97.0%	0.9444
Random	34.0%	0.3239



발견 1 — PPO가 Warmup 대비 오히려 성능을 떨어뜨림 (노란 행 = SRAS PPO)

- **SRAS PPO가 Warmup보다 낮음** — 학습 중 관찰된 policy drift가 테스트셋 일반화에 부정적 영향을 미친 것으로 해석됨
- **Cosine Top-K가 여전히 최상위** — 97.0% / 0.9444로 모든 모델 중 최고. PPO 학습이 기반 임베딩 모델의 내재적 표현력을 아직 충분히 활용하지 못하고 있음을 시사
- **학습 hit rate(90~95%)와 테스트 결과(83.5%)의 괴리** — 보상 함수가 학습 분포에 과적합되거나, 생성기가 틀린 문서로도 높은 보상을 받는 noise signal 문제가 일반화를 저해했을 가능성

Seed 실험 및 신뢰구간 — 단일 시드의 한계와 보완 설계

현재 실험의 한계

- 모든 결과가 단일 시드(seed = 42)에서 도출됨
- 결과의 신뢰구간(CI)을 산출할 수 없어, 차이가 알고리즘 효과인지 무작위 변동인지 통계적으로 확정 짓기 어려움
- → 본 보고서의 모든 비교는 “경향성의 관찰”로 해석해야 하며, 일반화에는 다중 시드 검증이 필요

제안: 다중 시드 실험 설계

시드 집합 { 42, 123, 2024, 7, 99 } × 각 5회 반복

- 동일 모델·하이퍼파라미터를 5개 시드로 반복 학습 → 평균 ± 표준편차로 신뢰구간 제시
- PPO vs Warmup의 성능 차이가 시드 변동 범위를 벗어나는지 검증 → “PPO 저하”가 통계적으로 유의한 경향인지 확인 가능

이론적 Random 기준선



$$\text{Hit@3} = K / n = 3 / 8 = 37.5\%$$

8개 후보 중 3개를 무작위로 뽑을 때 gold 1개가 포함될 기댓값. 실험에서 관측된 Random Hit@3(34.0%)는 이 이론값 부근에서 표본 별로 변동하는 정상 범위로 해석할 수 있음 — 다중 시드 실험을 통해 이 변동 폭 자체도 정량화할 수 있음



COMPARISON WITH THE REFERENCE PAPER

원 논문(SRAS, Muttur 2026)과의 비교

참고 논문 소개 — 본 프로젝트가 기반한 연구

SRAS: Sparse Reward-Aware Selector for Edge-Native RAG Pipelines

Muttur et al. · 2026 · arXiv:2601.01785 · *ICEdge 2025 Best Paper 후보*

본 프로젝트는 이 논문의 핵심 아이디어 — 경량 스코어링 함수 구조, PPO 기반 강화학습 미세조정, 엣지 배포를 위한 모델 경량화 설계 — 를 한국어 법률 QA 도메인으로 이식·재현하는 것을 목표로 출발하였음

논문의 핵심 내용 (영어·일반 도메인 환경)



RL 기반 문서 선택기 제안

Edge RAG 파이프라인에서 PPO로 학습되는 경량 문서 선택 모듈을 제안



905개 문서 · MiniLM(384d) · T5

영어 일반 문서 컬렉션, 384차원 인코더와 T5 생성기로 구성된 파이프라인에서 검증



“PPO가 supervised보다 개선”

SRAS-PPO의 Relaxed F1(0.1473)이 Supervised-FF(0.1323)보다 높음을 핵심 성과로 보고

충실히 재현한 요소 — 핵심 설계는 그대로 사용

논문의 핵심 아이디어를 다른 언어·도메인에서도 “같은 조건”으로 검증하기 위해, 다음 요소들은 의도적으로 동일하게 유지함

	스코어링 함수 구조 동일	$s_i = w^T \cdot \tanh(W_q \cdot q + W_d \cdot d_i)$ — additive interaction 구조를 그대로 적용한 경량 스코어러
	후보 풀 구성 동일	후보 $n = 8$ (1 gold + 7 distractor), 최종 선택 Top-K = 3
	PPO 핵심 하이퍼파라미터 일치	Clip $\epsilon = 0.2$, Discount $\gamma = 0.99$, AdamW · lr = $1e-5$ · epochs = 25 · batch = 8
	보상 가중치 $\alpha = 0.6$ 동일 적용	F1과 BERTScore를 6:4 비율로 결합하는 하이브리드 보상 설계를 계승
	훈련 안정화 기법 공유	Supervised Warmup, Hybrid Reward, Reward Normalization 등 핵심 안정화 장치를 동일하게 채택

도메인 적용과 확장 — 무엇을 바꾸고, 무엇을 더했는가

비교 항목	원 논문 (Muttur 2026)	본 프로젝트
도메인 / 문서 수	영어 일반 문서 · 905개	한국어 법률 QA · 712개 (642+70)
인코더 (임베딩 차원)	MiniLM · 384차원	ko-sroberta · 768차원
생성기 (Generator)	T5	qwen3.5:2b (Ollama)
파라미터 수 / 모델 크기	약 197K / 0.76 MB	98,368 / 0.38 MB (약 절반)
보상 구조	2-항 (F1 + BERTScore)	3-항 (+ Doc Hit Bonus) 추가
평가 지표	간접 — Relaxed F1, BERTScore	Hit Rate, MRR 추가
실행 하드웨어	Intel i5 (CPU)	Apple M4 (MPS)




평가 지표 설계의 함의

원 논문은 생성 품질 기반의 간접 지표(Relaxed F1·BERTScore)로 성능을 측정함. 그러나 본 프로젝트의 Hit/Miss 분석에서 보듯, 생성기는 틀린 문서를 받고도 그럴듯한 답변을 만들어낼 수 있어 간접 지표만으로는 검색 실패가 가려질 위험이 있음. 본 프로젝트가 추가한 직접 지표(Hit Rate·MRR)는 선택기가 실제로 정답 문서를 골랐는지를 곧바로 진단한다.

핵심 발견 — 같은 알고리즘, 정반대의 결론

원 논문의 결론

Table II · Relaxed F1



SRAS-PPO (0.1473) ▲ Supervised-FF (0.1323)


→ 결론:

“PPO 강화학습 미세조정이 supervised 모델보다 성능을 향상시킨다”

VS

본 프로젝트의 결과

테스트셋 · Hit Rate@3



SRAS-PPO (83.5%) ▼ SRAS-Warmup (91.5%)

→ 결론:

“PPO 강화학습 미세조정이 오히려 검색 성능을 저하시킨다(-8%)”



DISCUSSION & CONCLUSION

개선 방안 및 결론

08

개선 방향 제안

1. 보상 신호 개선

Gold doc hit 기반 이진 보상으로 직접
정렬, 더 강력한 생성 모델
(qwen2.5:14b) 활용

2. 훈련 데이터 확장

현재 800개 QA pair는 일반화 학습에
부족 — 5,000개 이상으로 확장하고 의
미적으로 유사한 문서를 구별하는 어
려운 케이스 포함

3. 다중 시드 실험

5개 이상의 랜덤 시드로 반복 학습 →
평균 ± 표준편차로 신뢰구간 제시, 알
고리즘 간 통계적 유의성 검증

결론

	Random 대비	우리 91.5% vs 34.0%	▲ + 57.5%p	학습 기반 검색의 최소 효과는 명확히 입증
	Cosine Top-K 대비	우리 91.5% vs 97.0%	▼ - 5.5%p	비학습 베이스라인에는 아직 도달하지 못함
	Warmup 대비 (PPO 저하)	우리 83.5% vs 91.5%	▼ - 8.0%p	RL 미세조정 단계에서 reward misalignment로 추정되는 역행 발생 — 가장 중요한 교훈!

엣지 배포 효율 0.38 MB · 0.033~0.038 ms (CPU/MPS) — 논문 대비 약 절반 크기로, 가볍고 빠른 구조 설계 자체는 성공

→ 모델 구조는 가볍고 빠르게 설계했지만, 강화학습 단계의 “보상 정렬(reward alignment)” 문제가 다음 과제로 남았다

감사합니다

SRAS — Sparse Reward-Aware Selector for Edge-Native RAG Pipelines

GitHub 저장소: [<https://github.com/kam5263/sras>]